

✖ PK1 Прокофьев Илья Викторович РТ5-61Б

✖ Вариант: 13

Задание

Для заданного набора данных проведите обработку пропусков в данных для одного категориального и одного количественного признака. Какие способы обработки пропусков в данных для категориальных и количественных признаков Вы использовали? Какие признаки Вы будете использовать для дальнейшего построения моделей машинного обучения и почему? Для пары произвольных колонок данных построить график "Jointplot".

✖ Описание набора данных

Датасет содержит информацию о факторах, влияющих на поступление в магистратуру. Целевая переменная — вероятность поступления (Chance of Admit).

Признаки:

- Serial No. — порядковый номер (не используется для моделирования)
- GRE Score — балл GRE (от 260 до 340)
- TOEFL Score — балл TOEFL (от 0 до 120)
- University Rating — рейтинг университета (от 1 до 5)
- SOP — сила мотивационного письма (от 1 до 5)
- LOR — сила рекомендательных писем (от 1 до 5)
- CGPA — средний балл (от 0 до 10)
- Research — наличие исследовательского опыта (0 или 1)
- Chance of Admit — вероятность поступления (от 0 до 1)

✖ Импорт библиотек

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Для воспроизводимости
np.random.seed(42)
```

✖ Загрузка данных

```
df = pd.read_csv('D:\\6 семестр\\ML\\PK\\Данные\\archive\\Admission_Predict.csv')
print("Первые 5 строк:")
display(df.head())
print("\nИнформация о пропусках:")
print(df.isnull().sum())
```

Первые 5 строк:

	Serial No.	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	Research	Chance of Admit
0	1	337	118	4	4.5	4.5	9.65	1	0.92
1	2	324	107	4	4.0	4.5	8.87	1	0.76
2	3	316	104	3	3.0	3.5	8.00	1	0.72
3	4	322	110	3	3.5	2.5	8.67	1	0.80
4	5	314	103	2	2.0	3.0	8.21	0	0.65

```
Информация о пропусках:
Serial No.      0
GRE Score      0
TOEFL Score    0
University Rating 0
SOP            0
LOR            0
CGPA           0
Research       0
Chance of Admit 0
dtype: int64
```

✖ Создание категориального признака на основе University Rating

```
# Разбиваем рейтинг на три категории: Low (1-2), Medium (3), High (4-5)
df['Rating Category'] = pd.cut(df['University Rating'],
                               bins=[0, 2, 3, 5],
                               labels=['Low', 'Medium', 'High'])

# Проверим распределение
print(df['Rating Category'].value_counts())
```

```
Rating Category
High      134
Low       133
Medium    133
Name: count, dtype: int64
```

✖ Искусственное внесение пропусков

```
# Для количественного признака (GRE Score) заменяем 5% случайных значений на NaN
n_missing = int(len(df) * 0.05)
missing_gre_idx = np.random.choice(df.index, size=n_missing, replace=False)
df.loc[missing_gre_idx, 'GRE Score'] = np.nan

# Для категориального признака (Rating Category) заменяем 5% случайных значений на NaN
missing_cat_idx = np.random.choice(df.index, size=n_missing, replace=False)
df.loc[missing_cat_idx, 'Rating Category'] = np.nan

print("Пропуски после внесения:")
print(df[['GRE Score', 'Rating Category']].isnull().sum())
```

```
Пропуски после внесения:
GRE Score      20
```

Rating Category	20
dtype: int64	

Обработка пропусков

```
# Количественный признак: заполнение медианой
gre_median = df['GRE Score'].median()
df['GRE Score'] = df['GRE Score'].fillna(gre_median)
print(f"GRE Score заполнен медианой: {gre_median}")

# Категориальный признак: заполнение модой (наиболее частой категорией)
cat_mode = df['Rating Category'].mode()[0]
df['Rating Category'] = df['Rating Category'].fillna(cat_mode)
print(f"Rating Category заполнен модой: {cat_mode}")

# Проверка, что пропусков больше нет
print("\nПропуски после обработки:")
print(df[['GRE Score', 'Rating Category']].isnull().sum())
```

GRE Score заполнен медианой: 317.0
Rating Category заполнен модой: Medium

Пропуски после обработки:
GRE Score 0
Rating Category 0
dtype: int64

Способы обработки пропусков:

- Для количественного признака (GRE Score) использована медиана, так как она устойчива к выбросам и не искажает распределение.
- Для категориального признака (Rating Category) использована мода (наиболее частое значение), что является стандартным подходом для номинальных признаков.

Признаки для дальнейшего построения моделей:

- Все числовые признаки (GRE Score, TOEFL Score, University Rating, SOP, LOR, CGPA, Research), кроме Serial No. (идентификатор).
- Категориальный признак Rating Category можно использовать после кодирования (например, one-hot encoding), но он дублирует информацию University Rating. Поэтому в модель лучше включить либо University Rating (как порядковый), либо Rating Category (как номинальный), либо оба, если есть основания считать, что нелинейное преобразование улучшит качество. В данном случае оставим исходные числовые признаки, так как они уже содержат всю информацию.
- Целевая переменная: Chance of Admit.

jointplot для двух произвольных колонок



